Aprendizaje no supervisado en SECOP II

Informe de resultados: clustering K-Means y detección de anomalías con Isolation Forest

Proyecto académico de minería de datos | Análisis de la muestra exportada de Orange Data Mining

Resumen ejecutivo

Se analizaron 4.000 filas exportadas de Orange Data Mining, correspondientes a 3.943 identificadores de proceso distintos. K-Means produjo seis clusters y Isolation Forest señaló 173 filas atípicas (4,33 %), asociadas a 126 identificadores de proceso distintos. El cluster C5 contiene 48 filas, de las cuales 44 (91,67 %) fueron marcadas como atípicas. Estos hallazgos priorizan observaciones para revisión, pero no constituyen etiquetas ni pruebas de fraude.

1. Pregunta y alcance

Pregunta de agrupamiento: ¿qué perfiles de procesos de contratación pública se identifican por sus características económicas, administrativas y de proveedores, y en qué perfiles se concentran observaciones estadísticamente atípicas?

Unidad analítica: fila del archivo exportado, no necesariamente proceso único. La muestra de 4.000 registros proviene de un Data Sampler reproducible. No se extrapolan porcentajes al universo de la contratación pública colombiana ni se infiere causalidad o fraude.

2. Preparación de datos y flujo utilizado

Flujo principal: CSV File Import → Select Columns → Impute → Continuize → Data Sampler → K-Means → Distributions / Box Plot / Silhouette Plot / Save Data. Rama complementaria: Data Sampler → Outliers (Isolation Forest) → Data Table / Save Data.

Variables utilizadas para agrupar: precio_base, modalidad_de_contratacion, tipo_de_contrato, ordenentidad y proveedores_unicos_con. Las tres variables categóricas se transformaron mediante one-hot encoding y las continuas mediante estandarización, según la configuración reportada. Impute se configuró como Average/Most frequent. El CSV de salida contiene 47 atributos del modelo (45 columnas binarias de categorías y dos variables numéricas).

Fuera de las variables predictoras: adjudicado, respuestas_al_procedimiento, valor_total_adjudicacion, departamento_entidad e identificadores (metadatos). En el archivo de Isolation Forest, adjudicado y departamento figuran como metadatos codificados en binario, no como atributos de entrada. Se verificó que los 47 atributos de ambos archivos coinciden, y también los 4.000 identificadores en el mismo orden.

Parámetros: Data Sampler de 4.000 filas, sin reemplazo y reproducible; K-Means con inicialización K-Means++, 10 reinicios y 300 iteraciones, sin normalización adicional; se compararon K = 2 a 6 y se utilizó K = 6 en la exportación. Outliers: Isolation Forest, con configuración de contaminación nominal del 5 % reportada en el flujo; el resultado efectivo exportado fue 4,33 %.

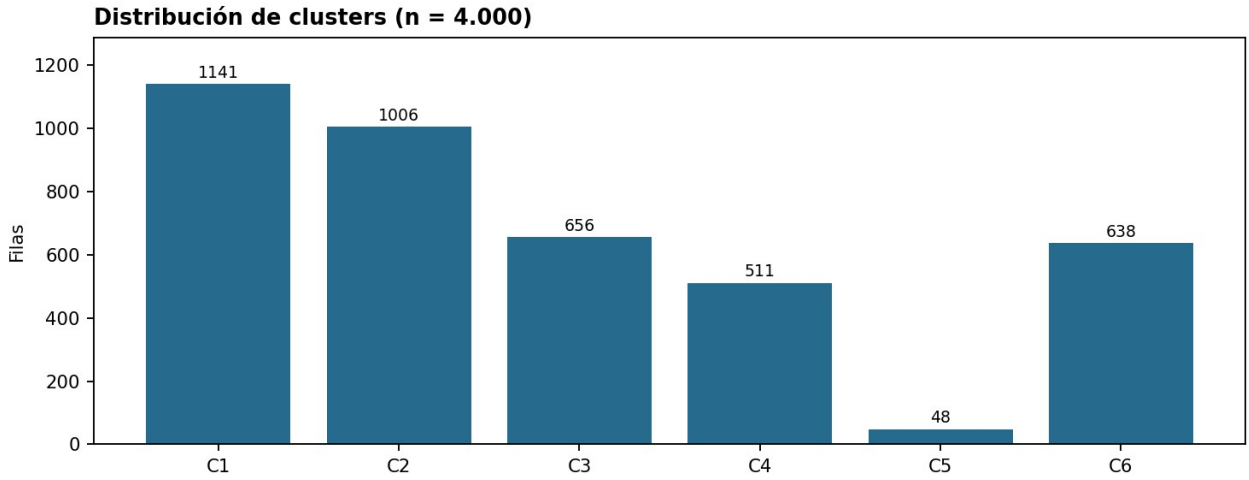
3. Comparación de valores de K

K	Silhouette mostrado en Orange (segunda prueba)

2	0,327
3	0,353
4	0,420
5	0,488
6	0,550

En la comparación visual de Orange, K = 6 presentó el mayor puntaje entre las opciones probadas. El archivo kmeans.tab exporta además una columna Silhouette por fila, cuya media es 0,645 y no coincide con el 0,550 mostrado en la captura. Por rigor, se presentan ambos datos por separado: las capturas justifican la elección preliminar de K y las filas exportadas sustentan la caracterización; no se asume que ambos valores corresponden exactamente a la misma evaluación.

4. Distribución y caracterización de los seis clusters



Grupo	Filas	% muestra	Modalidad predominante	Tipo contractual predominante
C1	1141	28.52 %	Contratación directa (100.0 %)	Prestación de servicios (96.4 %)
C2	1006	25.15 %	Contratación régimen especial (68.8 %)	Prestación de servicios (62.3 %)
C3	656	16.40 %	Contratación directa (100.0 %)	Prestación de servicios (95.0 %)
C4	511	12.78 %	Contratación régimen especial (96.5 %)	Decreto 092 de 2017 (100.0 %)
C5	48	1.20 %	Contratación régimen especial (con ofertas) (68.8 %)	Suministros (31.2 %)
C6	638	15.95 %	Contratación régimen especial	Prestación de

	(37.8 %)	servicios (34.0 %)

C1 — Perfil interpretativo

Contratación directa territorial de servicios. El 100 % se agrupa en contratación directa; 96,4 % es prestación de servicios y 98,2 % corresponde a orden territorial. No registra adjudicaciones afirmativas en esta muestra.

C2 — Perfil interpretativo

Contratación territorial mixta de régimen especial y cuantías menores. Predominan régimen especial (68,8 %) y prestación de servicios (62,3 %); hay diversidad de objetos y algunas adjudicaciones registradas.

C3 — Perfil interpretativo

Contratación directa nacional de servicios. El 100 % pertenece a orden nacional y contratación directa; 95,0 % corresponde a prestación de servicios. Se distingue de C1 sobre todo por el orden de entidad.

C4 — Perfil interpretativo

Procesos asociados al tipo contractual Decreto 092 de 2017. El 100 % presenta esta categoría contractual y 96,5 % tiene modalidad de régimen especial; combina órdenes territorial y nacional.

C5 — Perfil interpretativo

Perfil minoritario de participación elevada y valores estandarizados extremos. Predominan régimen especial con ofertas (68,8 %) y suministros (31,2 %); presenta un promedio de 46,19 respuestas registradas por fila y 91,67 % de anomalías estadísticas.

C6 — Perfil interpretativo

Contratación nacional heterogénea. 98,9 % es de orden nacional; combina régimen especial, mínima cuantía y subasta inversa, con diversos tipos contractuales y mayor presencia relativa de anomalías.

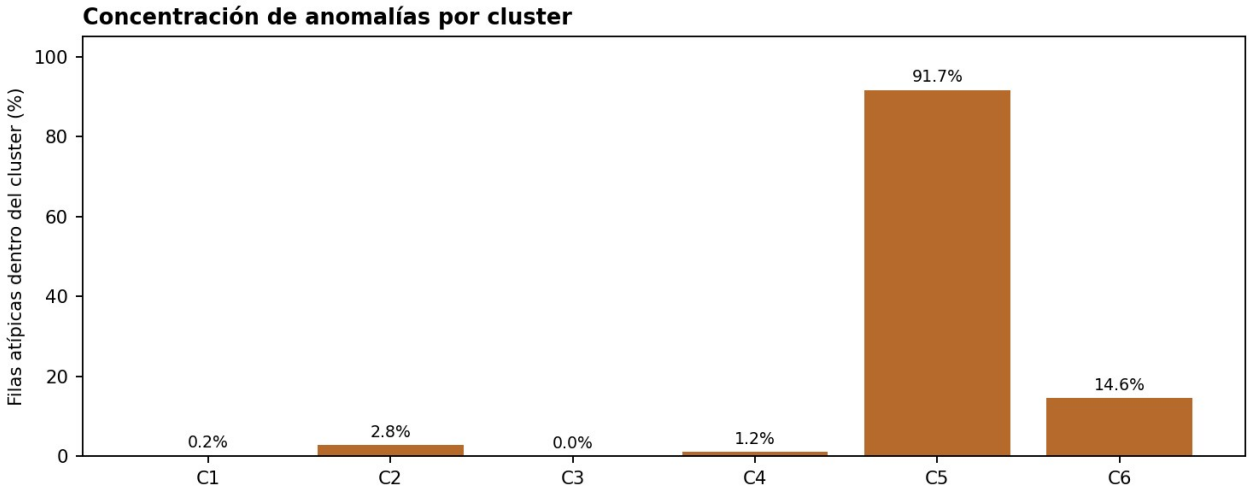
5. Evaluación por Silhouette y cautelas

Cluster	Media Silhouette del .tab	Filas
C1	0.732	1141
C2	0.563	1006
C3	0.734	656
C4	0.681	511
C5	0.616	48
C6	0.502	638

La media ponderada de la columna Silhouette del archivo exportado es 0,645. Los seis grupos tienen medias positivas en ese archivo; C6 registra el valor medio más bajo (0,502). La discrepancia con algunas capturas previas sugiere que se deben conservar juntos el archivo .ows y el exportado de una misma ejecución para

asegurar trazabilidad. La separación puede verse favorecida por atributos one-hot y por valores extremos; un Silhouette elevado no equivale a validez de indicadores de fraude.

6. Isolation Forest y distribución de anomalías



Cluster	Atípicas / filas	Tasa dentro de grupo
C1	2 / 1141	0.18 %
C2	28 / 1006	2.78 %
C3	0 / 656	0.00 %
C4	6 / 511	1.17 %
C5	44 / 48	91.67 %
C6	93 / 638	14.58 %

Se encontraron 173 filas atípicas (4,33 % de 4.000), correspondientes a 126 identificadores de proceso distintos. C6 aporta 93 de las filas atípicas y C5 aporta 44. C5 posee la mayor tasa relativa de anomalías (44/48 = 91,67 %); C6 tiene una tasa del 14,58 %. Los conteos y porcentajes se refieren a filas de la muestra y NO a procesos únicos ni casos de fraude.

La proporción observada de atípicos puede diferir de la contaminación configurada por la forma en que el algoritmo fija su umbral, los empates o la configuración exacta del widget. La exportación no contiene un puntaje continuo de anomalía, por lo que no se puede ordenar rigurosamente los 173 registros por severidad dentro de cada grupo.

7. Utilidad para priorización de revisiones

C5 merece revisión contextual prioritaria por combinar un tamaño minoritario con concentración de anomalías y participación muy elevada. C6 merece revisión por aportar la mayor cantidad absoluta de filas atípicas. C2 también tiene observaciones aisladas. Ninguno de estos rasgos demuestra corrupción; pueden responder a diferencias legítimas entre modalidades, entes o contratos.

Se entrega un CSV de 173 filas para revisión, con los identificadores y el cluster correspondiente. La etiqueta de prioridad es puramente exploratoria: no es un dictamen jurídico, sancionatorio ni de riesgo de fraude

confirmado. Antes de abrir una investigación se deben revisar el expediente completo, el alcance contractual, los montos originales, el número de proponentes válidos y las actualizaciones de cada proceso.

8. Limitaciones y control de calidad

- Los 4.000 registros son una muestra, no la totalidad del archivo de aproximadamente 700 MB. No se deben generalizar proporciones sin revisar la estrategia de muestreo.
- Hay 3.943 IDs de proceso distintos; algunos procesos figuran en varias filas. El análisis cuantitativo de filas no sustituye el análisis por proceso.
- precio_base y proveedores_unicos_con están estandarizados en los archivos exportados; no pueden interpretarse directamente como COP o número de proveedores sin recuperar sus valores originales.
- Las etiquetas de riesgo de Perplexity y los indicadores heurísticos no están incorporados en las dos exportaciones; por tanto, no se verificó todavía concordancia con un puntaje de riesgo externo.
- No hay etiquetas verificadas de fraude/sin fraude. No es posible calcular precisión o recall de detección de fraude para Isolation Forest con esta evidencia.
- El conjunto de variables categóricas y las diferencias de escalas pueden dominar los grupos; se recomienda evaluar estabilidad, transformación logarítmica de precio y muestreo en trabajos posteriores.
- Se han observado divergencias entre capturas y exportación de Silhouette. Se recomienda una exportación sincronizada del flujo Orange antes de la entrega final.

9. Conclusiones

1. El agrupamiento K-Means identificó seis perfiles descriptivos diferentes de contratación pública en las 4.000 filas de la muestra, con una solución K = 6 preferida de forma preliminar entre las alternativas evaluadas.
2. Los clusters están asociados principalmente con modalidad, tipo de contrato y orden de entidad; algunos también difieren por participación y por valores estandarizados de precio.
3. Isolation Forest detectó 173 filas atípicas. La mayor concentración relativa está en C5 (91,67 %), mientras que C6 reúne el mayor número absoluto (93 filas).
4. La combinación de perfiles y anomalías ofrece un mecanismo reproducible para seleccionar expedientes que merezcan comprobación, pero no permite detectar ni predecir fraude confirmado.
5. La siguiente etapa de investigación debe incorporar indicadores de riesgo auditables, revisión de expedientes y, cuando sea posible, etiquetas oficiales verificadas.

Archivos de soporte

kmeans.tab y outliers.tab: exportaciones originales recibidas. secop_resultados_no_supervisados.csv: unión validada por orden de fila, entidad e ID. resumen_clusters_secop.csv: métricas descriptivas exactas. procesos_atipicos_para_revision.csv: 173 filas atípicas para revisión. Los nombres categóricos fueron recuperados desde las columnas one-hot de las exportaciones.